Pesquisa - Alucinação de IA

Tópicos de Fundamentos:

É quando um modelo de IA gera uma resposta que parece confiante, fluente e coerente, mas que é factualmente incorreta, contradiz o contexto fornecido ou é completamente inventada.

- Missão sugerida - “Confiança enganosa”: jogador recebe 3 respostas de IA sobre um mesmo tema e todas parecem bem escritas e corretas, mas só uma é correta. O jogador deve escolher a certa sem usar fontes externas.
- Propósito: o jeito que está escrito não é indicador de verdade

A IA não busca a "verdade", e sim padrões estatísticos.

- **Pré-treinamento:** O modelo é alimentado com uma quantidade imensa de dados. Ele aprende prevendo a próxima palavra em uma sequência com base em padrões probabilísticos. Se a informação que você busca é rara ou ambígua nos dados de treinamento, o modelo pode "adivinhar" a resposta mais provável estatisticamente, que pode ser uma invenção . A pesquisa mostra que, se um fato específico (como uma data de aniversário) aparece apenas uma vez nos dados de treinamento, o modelo pode ter uma taxa de erro (alucinação) sobre aquele fato na mesma proporção.
    - Missão sugerida - “O Fato Raro”: O jogador faz uma pergunta sobre um fato muito específico e incomum. O jogo mostra a resposta da IA, que é plausível, mas é inventada. O jogador deve decidir entre aceitar, duvidar ou rejeitar

- **Pós-treinamento:** Mesmo depois dos ajustes para diminuir os erros, as alucinações persistem. Uma razão para isso é que os sistemas de avaliação de IA muitas vezes recompensam respostas e penalizam a incerteza . É como em uma prova de múltipla escolha onde "chutar" uma resposta, mesmo sem saber, pode te dar um ponto, mas deixar em branco não. Assim, a IA é incentivada a sempre dar uma resposta, por mais duvidosa que seja .
    - Missão sugerida - “O dilema do chute”: o jogador assume o papel de um sistema de avaliação de IA. Ele deve decidir se recompensa uma resposta correta, uma resposta incerta (“não sei”) ou uma resposta inventada. O jogo mostra as consequências de cada escolha ao longo de várias rodadas, se o sistema recompensa respostas mesmo quando erradas, a IA aprende a chutar sempre e as alucinações aumentam

Funcionamento

Pesquisas mais aprofundadas descrevem o processo de raciocínio da IA como uma navegação em um "mapa mental". Imagine um mapa onde cada conceito é um ponto e as relações entre eles são caminhos . A alucinação ocorre por dois mecanismos principais:

- Reutilização de Caminhos (Path Reuse): No início do treinamento, o modelo pode "pegar atalhos" e aplicar um caminho de raciocínio que funcionou para um assunto em um contexto completamente diferente, ignorando as restrições do novo contexto .
    - Missão sugerida - "Atalho perigoso": o jogador vê uma IA resolvendo um problema novo usando um raciocínio que funcionou em um problema antigo, mas não se aplica ao contexto atual. O jogador deve identificar qual restrição do novo contexto foi ignorada e onde o caminho antigo foi reutilizado indevidamente

- Compressão de Caminhos (Path Compression): Conforme o treinamento avança, caminhos frequentemente usados são "encurtados" para serem mais eficientes. A IA deixa de passar por todas as etapas intermediárias de raciocínio e "pula" para uma conclusão. Se o caminho original tinha erros ou era uma correlação, essa compressão solidifica a alucinação como um padrão "válido" para o modelo .

    - Missão sugerida - "O salto da conclusão": o jogador recebe uma cadeia de raciocínio completa (com todas as etapas intermediárias) e uma versao comprimida da mesma cadeia (com etapas puladas). O jogador deve identificar qual etapa intermediária foi removida e se essa remoção introduziu um erro.
    - Mecânica de quebra cabeça de ordenação: o jogador arrasta as etapas de volta para a posição correta e verifica se a conclusão comprimida ainda se sustenta

Causas e riscos

Dados ruins: Se a IA aprende com informações erradas ou desatualizadas, ela repete esses erros.

- Missão sugerida - "A Fonte envenenada": o jogador deve treinar uma IA fictícia com um conjunto de dados que contém informações erradas propositalmente. Depois, faz

perguntas à IA e observa que ela repete os erros. O jogador deve identificar quais dados estavam corrompidos e removê-los antes de treinar novamente
- Mecânica: o jogador inspeciona um conjunto de dados, marca os itens suspeitos, e ve o impacto da limpeza na qualidade das respostas da IA

Limitação do modelo: A IA enxerga apenas coincidências, não relações de causa e efeito. Ela junta coisas que aparecem juntas nos dados, mesmo sem ligação real.

- Missão sugerida - “Correlação não é causa”: o jogador vê uma IA que afirma: “sempre que X acontece, Y acontece junto, logo X causa Y”. O jogador deve identificar onde está o salto lógico e qual seria a explicação alternativa

Pergunta mal feita: Se o usuário dá instruções confusas, a IA inventará informações para preencher as lacunas e manter a coerência.

- Missão sugerida - “A lacuna preenchida”: o jogador faz uma pergunta ambígua ou incompleta para uma IA. A IA responde com uma invenção para fechar a lacuna. O jogador deve reescrever a pergunta de forma clara e ver se a IA ainda alucina.

Tipos de Alucinações

Intrínsecas: Ocorrem quando a resposta contradiz a informação fornecida pelo usuário ou o contexto dado. É uma falha de "atenção" ao que foi pedido.

- Missão sugerida - “O contexto ignorado”: o jogador fornece um contexto detalhado para a IA e ela responde contradizendo esse contexto. O jogador deve apontar exatamente qual informação do contexto foi contradita.

Extrínsecas: Ocorrem quando a resposta não pode ser verificada ou é completamente inventada, mesmo que não contradiga o contexto. É uma "criatividade" indesejada.

- Missão sugerida - “A invenção plausível”: o jogador recebe uma resposta que não contradiz nada do contexto fornecido, mas que não pode ser verificada em nenhuma fonte confiável. O jogador deve decidir: é uma alucinação extrínseca ou uma informação válida que apenas não está no contexto

Como Mitigar:

- Verificação Humana

- Missão sugerida - “O revisor humano”: jogador atua como revisor humano de respostas de IA. Ela recebe várias respostas e deve aprovar, rejeitar ou pedir revisão para cada uma. O jogo mede quantas alucinações o jogador deixou passar e quantas ele rejeitou injustamente.

- Validação com Fontes Externas
  - Missão sugerida - “ A fonte cruzada”: o jogador deve comparar a resposta da IA com duas ou três fontes externas fornecidas pelo jogo. Se as fontes discordam entre si ou da IA, o jogador deve identificar qual é a mais confiável e por que

- Uso de Técnicas Específicas, métodos como RAG, que conecta o modelo a uma base de dados confiável em tempo real.
  - Missão sugerida - “A base de dados confiável” - Pensei em um dos objetos ser um RAG: o jogador opera um sistema RAG simplificado. Ele deve quais documentos recuperar a uma pergunta. Se recuperar o documento errado, a IA alucina. Se recuperar o documento certo, a IA responde corretamente.

- Perguntas Diretas e Contexto Claro.

  - Missão sugerida - “A pergunta perfeita” - Um dos objetos ser uma pergunta/algo que a aperfeiçoe: o jogador deve reformular uma pergunta direta e com contexto claro. O jogo compara a taxa de alucinação da pergunta original com a da pergunta formulada.

Fontes:

[2509.04664] Why Language Models Hallucinate

O que são alucinações de IA? | Cloudflare

ICML Poster When Do Hallucinations Arise? A Graph Perspective on the Evolution of Path Reuse and Path Compression

Hallucinations in generative artificial intelligence and large language models: tests, datasets, detection and correction methods | Language Resources and Evaluation | Springer Nature Link

O que é alucinação de IA e como evitar erros?

[Large language models hallucination: A comprehensive survey - ScienceDirect]

Tópicos de Aprofundamento:

1. Alucinação em múltiplos passos e agentes:
    - Por que incluir: os fundamentos focam em respostas de turno único, em que há apenas uma sequência de perguntas e respostas sem continuidade, o que não reflete a complexidade das interações atuais. Modelos modernos como agentes que executam sequências de ações (planejar -> recuperar- > raciocinar -> usar ferramentas). Uma alucinação em uma etapa intermediária se propaga pelas etapas seguintes, degradando toda a trajetória
    - Desafio para o jogo: missões onde o jogador deve identificar em qual etapa de um fluxo multi-step ocorreu o erro (planejamento, recuperação, raciocínio, tool-use, interação humana)
    - Fonte: https://arxiv.org/abs/2601.06818?context=cs#1

2. Taxonomia multidimensional de tipos de alucinação:
    - O documento inclui a alucinação extrínseca e intrínseca. A literatura recente expande para 4 dimensões:
        - Factualidade: contradiz fatos do mundo real
        - Fidelidade: Contradiz o contexto/output fornecido
        - Lógica: raciocínio inválido mesmo com premissas corretas
        - Híbrida emergente: combinação das anteriores, incluindo inconsistências multimodais
    - Desafios para o jogo: onde o jogador classifica a alucinação em uma dessas 4 categorias
    - Fonte: https://xplorestaging.ieee.org/document/11189137

3. RAG e suas falhas:
    - Por que incluir: RAG também pode causar alucinações. O estudo linkado identifica a recuperação de texto puro sofre de “conexões lógicas quebradas” entre chunks, resultando em alucinações frequentes. Há

também o fenômeno de Conflito de Informação entre o conhecimento interno do modelo e os dados recuperados externamente
- Desafio para o jogo: missão onde o jogador deve detectar quando o RAG recuperou um documento errado (mas plausível) e o modelo alucinou a partir dele
- Cenário de conflito: a IA sabe X, o RAG recupera Y, qual seguir?
- Fontes: https://ieeexplore.ieee.org/document/11655161#1 ; https://garuda.kemdiktisaintek.go.id/author/view/1507958?jid=26469&jname=Edukasia:+Jurnal+Pendidikan+dan+Pembelajaran

4. Causas específicas do ciclo de vida do desenvolvimento

- Por que incluir: a literatura mapeia causas em 3 estágios para além do pré e pós treinamento
- Nível de dados: lacunas de conhecimento, desinformação, ruído de anotação
- Induzidas pelo treinamento: imitação distribucional, viés de recompensa, alignment forgetting
- Vulnerabilidade na inferência: má calibração de confiança, falhas de decodificação, erros induzidos por prompt
- Desafios para o jogo: o jogador traça a origem de uma alucinação até seu estágio no ciclo de vida
- Fontes: https://xplorestaging.ieee.org/document/11189137 ; https://www.sciencedirect.com/science/article/abs/pii/S157401372600078X#1

Ideia: o puzzle corresponder ao momento que a IA alucionou e é preciso descobrir por que aconteceu. Cada motivação é conteudo para um puzzle e associada a um objeto (pergunta, RAG). O jogador deve perceber que o bloco 2 demonstra como a Luci alucinou e a batalha final é reverter esse processo usando os objetos na ordem certa